

# 네트워크 침입 탐지 시스템

이제우

삼성아카데미

예측 자동화 서비스과정

개인 프로젝트

# 목차

01    개요

02    계획

03    데이터 분석

04    설계

05    평가

05    향후계획

05    출처

# 1. 개요

CIC-IDS-2017 기반 데이터를 이용하여 네트워크 트래픽 로그 기반으로 정상과 다양한 공격 유형을 자동으로 분류하는 네트워크 침입 탐지 시스템을 개발하여

침입탐지 성능을 측정하고, 주요 피처와 오류 원인을 분석해 실전 적용 가능성 평가

## 2. 계획


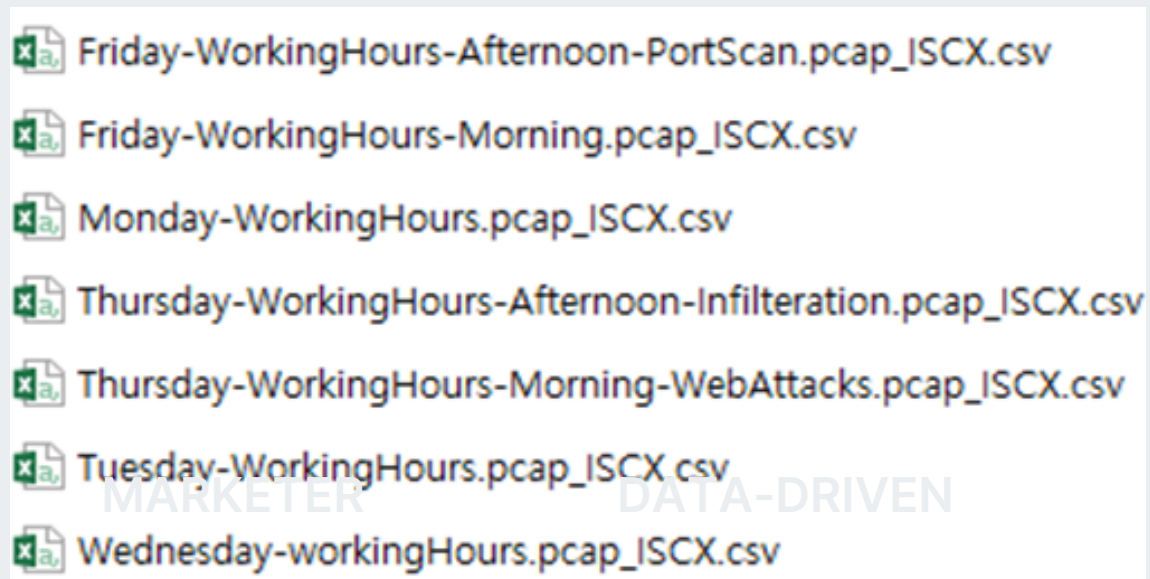
CIC-IDS-2017은 피쳐 기반 정형 데이터라 CNN/LSTM보단 MLP(DENSE 구조) 가 적합하다 판단, DENSE는 모든 피쳐 조합을 학습하기 때문에 희소 클래스 패턴까지 놓치지 않고 잡아낼 수 있을것으로 기대

### 3. 데이터분석

캐나다 통신보안연구소(CSE) 산하 CIC에서 2017년7월3일~7일 5일간 수집하여 가공한 네트워크 공격 탐지 연구용 공개 데이터셋(IDS-2017)

8개의 CSV파일, 약 280,000행

문제: 정상 85%-공격15%의 불균형, 공격 라벨별 데이터 불균형



Label		
DoS Hulk		231073
PortScan		158930
DDoS		128027
DoS GoldenEye		10293
FTP-Patator		7938
SSH-Patator		5897
DoS slowloris		5796
DoS Slowhttptest		5499
Bot		1966
Web Attack	Brute Force	1507
Web Attack	XSS	652
Infiltration		36
Web Attack	Sql Injection	21
Heartbleed		11

### 3. 데이터분석

70개의 피쳐중 중요 피쳐 분류결과:

BWD PACKET LENGTH MIN: 역방향(서버→클라이언트) 패킷 길이 최소값

PSH FLAG COUNT: TCP PUSH 플래그가 설정된 패킷 개수

ACT\_DATA\_PKT\_FWD: 순방향(ACTIVE) 데이터 패킷 수

BWD PACKET LENGTH STD: 역방향 패킷 길이의 표준편차

TOTAL LENGTH OF BWDPACKETS: 역방향 전체 바이트 합계

공격 트래픽은 보통 응답 패킷이 지나치게 짧거나 불규칙하고,  
요청·응답 균형이 무너지며특정 플래그가 비정상적으로 많이발생하는것을 확인

feature_importance_all.csv X	
reports > feature_importance_all.csv > data	
1	feature,gain,weight,cover
2	Bwd Packet Length Min,4813.0634765625,341.0,9234.6982421875
3	PSH Flag Count,3507.42822265625,519.0,7162.5439453125
4	act_data_pkt_fwd,2448.46435546875,622.0,9073.685546875
5	Bwd Packet Length Std,1563.3759765625,902.0,15335.654296875
6	Total Length of Bwd Packets,1499.501953125,1301.0,6306.8046875

# 4. 설계

1차BASELINE  
(MLP, BATCH=512, EPOCHS=40, CLASS WEIGHT-100)

데이터 분할 TRAIN7:VAL1:TEST2

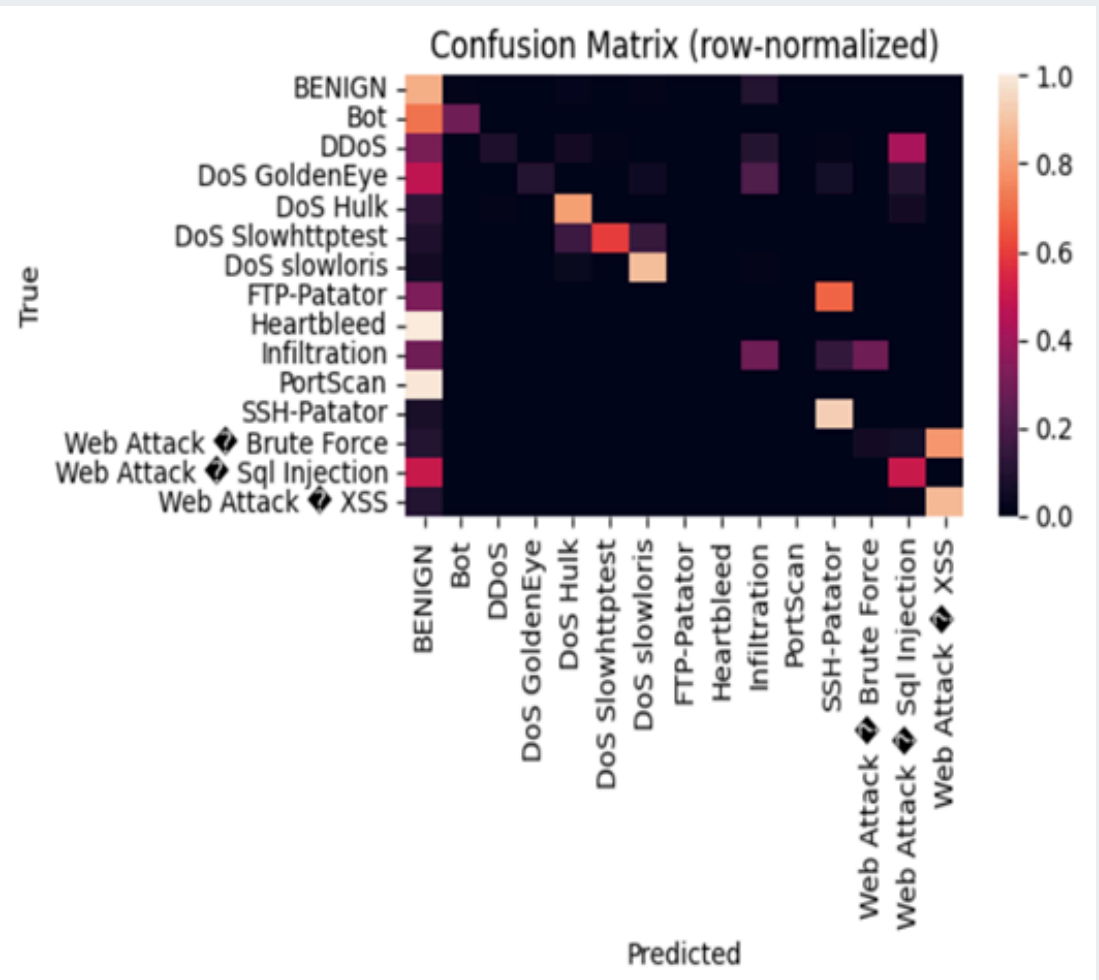
결과: BENIGN/대규모 공격만 잘 맞춤,  
희소 클래스 RECALL ↓

희소클래스들의 표본이 너무 적어 지표가 매우 불안정

극 희소클래스를 위한 과도한 가중치 편향으로인해  
학습이 흔들렸다 판단

TEST-MACRO AVG: PRECISION 0.27 / RECALL 0.42 / F1 0.24

						precision	recall	f1-score	support
1									
2									
3					BENIGN	0.92	0.84	0.88	418276
4					Bot	0.03	0.29	0.05	391
5					DDoS	0.55	0.08	0.14	25603
6				DoS	GoldenEye	0.82	0.09	0.17	2057
7					DoS Hulk	0.73	0.81	0.77	34570
8				DoS	Slowhttptest	0.29	0.60	0.39	1046
9					DoS slowloris	0.12	0.89	0.21	1077
10					FTP-Patator	0.00	0.00	0.00	1187
11					Heartbleed	0.00	0.00	0.00	2
12					Infiltration	0.00	0.29	0.00	7
13					PortScan	0.00	0.00	0.00	18164
14					SSH-Patator	0.25	0.93	0.39	644
15		Web Attack	💎	Brute Force		0.05	0.05	0.05	294
16	Web Attack	💎	Sql Injection			0.00	0.50	0.00	4
17			Web Attack	💎	XSS	0.32	0.88	0.47	130
18									
19					accuracy			0.77	503452
20					macro avg	0.27	0.42	0.24	503452
21					weighted avg	0.84	0.77	0.79	503452



# 4. 설계

2차- 가중치 조정으로 보완 시도  
(BENIGN축소,CAP=100, CLASS WEIGHT-70)

소수 클래스 RECALL ↑

3차- 소수클래스 데이터 증강으로 보완 시도  
SMOTE(CAP=15,000(최대 2배), CLASS WEIGHT-50))

소수 클래스 학습 기회 확대, 일부 F1-SCORE 개선

여전히 극심한 라벨간 불균형과 WEIGH의 편향으로 LOSS피크 발생

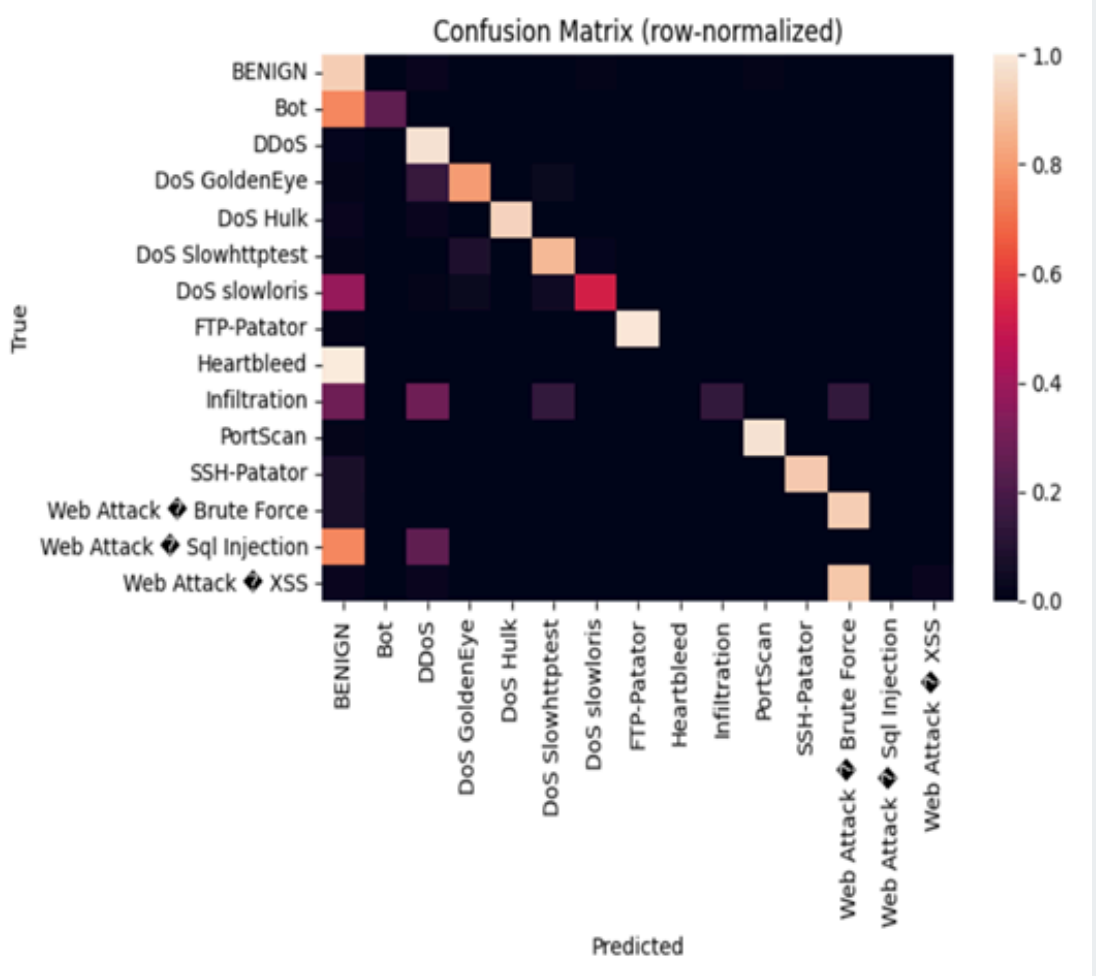
4차(MLP최종)- 파라미터 튜닝 배치사이즈 조정  
BATCH=512 → 256, CLASS WEIGHT-30

LOSS안정화, 성능 일부 개선  
지표는 1차에 비해 다소 안정됐지만 희소클래스가 상대적 학습기회를 보장받지 못했음

최종 TEST-MACRO AVG: PRECISION 0.56 / RECALL 0.62 / F1 0.56

1차 대비 TEST-MACRO AVG: PRECISION 0.29 / RECALL 0.20 / F1 0.30 개선

					precision	recall	f1-score	support
1								
2								
3				BENIGN	0.98	0.93	0.96	170351
4				Bot	0.45	0.25	0.32	391
5				DDoS	0.80	0.98	0.88	25603
6			DoS	GoldenEye	0.69	0.80	0.74	2057
7				DoS Hulk	0.99	0.94	0.97	34570
8		DoS	Slowhttptest		0.38	0.87	0.52	1046
9			DoS	slowloris	0.19	0.53	0.28	1077
10				FTP-Patator	0.98	0.99	0.99	1187
11				Heartbleed	0.00	0.00	0.00	2
12				Infiltration	0.00	0.14	0.01	7
13				PortScan	0.89	0.98	0.93	18164
14				SSH-Patator	0.99	0.92	0.95	644
15	Web Attack	⬢	Brute Force		0.67	0.93	0.78	294
16	Web Attack	⬢	Sql Injection		0.00	0.00	0.00	4
17			Web Attack	⬢ XSS	0.44	0.03	0.06	130
18								
19				accuracy			0.94	255527
20				macro avg	0.56	0.62	0.56	255527
21				weighted avg	0.95	0.94	0.94	255527





## 4. 설계

CIC-IDS-2017은 피쳐 기반 정형 데이터로, 초기에는 MLP(DENSE 구조)가 적합하다고 판단

DENSE는 모든 피쳐 조합을 학습할 수 있어 희소 클래스 패턴까지 잡아낼 수 있을 것으로 기대하여, CLASS WEIGHT 조정과 배치 사이즈 변경을 통해 불균형 문제를 완화하고자 하였다.

또한 SMOTE를 적용해 희소 클래스 학습 기회를 확장하려 했으나, 시간상 실사용이 가능한 정도의 성능 개선에는 한계가 있다고 판단

이에 따라 최종적으로는 소수 클래스에 강하고 빠른 학습이 가능한 머신러닝 알고리즘인 XGBOOST로 방향 전환

## 4. 설계

트리·부스팅 모델(XGBOOST)은 숫자 피처에 최적화

소수 클래스가 TRAIN에 0개면 그 클래스는 못 맞춤 → 최소 샘플 보장으로 극소수 클래스 보완

데이터 분할 TRAIN7:VAL1:TEST2

하이퍼파라미터:

MAX\_DEPTH=8 표현력 VS 과적합 균형

SUBSAMPLE/COLSAMPLE\_BYTREE=0.8: 매 라운드 부분 샘플링으로 과적합 억제

VALIDATION SET을 이용해 EARLY STOPPING 및 하이퍼파라미터 튜닝

클래스 가중치(CLASS\_WEIGHT =INV/INVSQRT): 정상-공격 불균형을 학습 단계에서 보정(소수 클래스 가중 ↑)

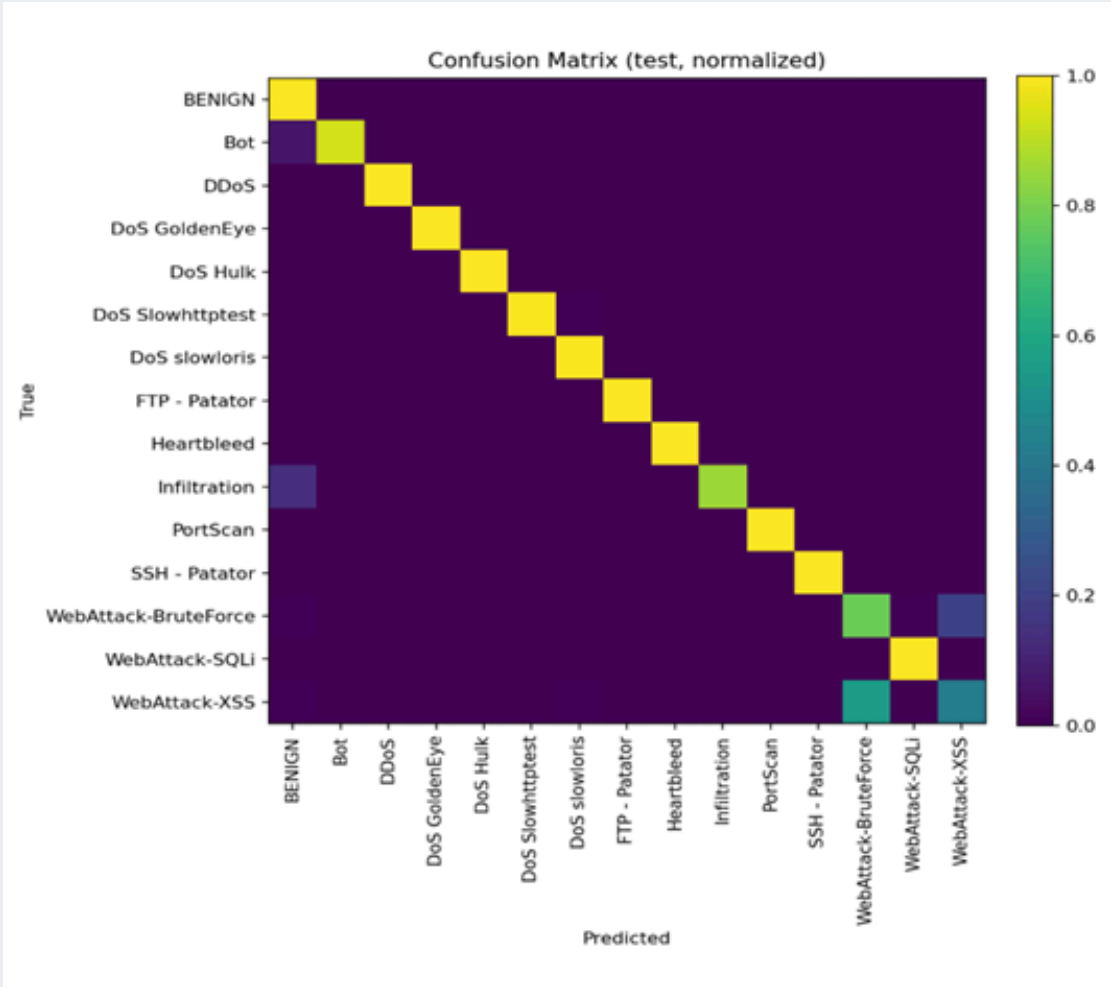
데이터 불균형 → (DATASET) 최소 학습샘플 보장 + (TRAIN) 가중치 학습 지원.

피처 누락/불일치 가능성 → (EVALUATE) ALIGN\_TO\_MODEL\_FEATURES로 자동 보정

4. 설계

전체적으로 높은 점수를 기록하였으나 일부 희소 클래스의 경우 표본의 부족으로인해 점수가 다소 떨어지는 경향을 보였다. 특히 WEB ATTACK 류의 공격은 CIC-IDS-2017 같은 정형(FLOW)데이터 이기에 콘텐츠(문자열) 기반 WEB 공격은 구분하기 어려운 특징을 보였다.

reports > ≡ classification_report_test.txt							
1				precision	recall	f1-score	support
2							
3			BENIGN	0.9999	0.9992	0.9996	454620
4			Bot	0.7764	0.9364	0.8489	393
5			DDoS	0.9998	0.9999	0.9999	25606
6		DoS	GoldenEye	0.9985	0.9985	0.9985	2059
7			DoS Hulk	0.9986	0.9998	0.9992	46215
8		DoS	Slowhttptest	0.9927	0.9936	0.9932	1100
9			DoS slowloris	0.9914	0.9957	0.9935	1159
10			FTP - Patator	1.0000	0.9994	0.9997	1588
11			Heartbleed	1.0000	1.0000	1.0000	2
12			Infiltration	1.0000	0.8571	0.9231	7
13			PortScan	0.9941	0.9996	0.9968	31786
14			SSH - Patator	0.9992	1.0000	0.9996	1179
15		WebAttack	BruteForce	0.7630	0.7807	0.7718	301
16			WebAttack-SQLi	0.6667	1.0000	0.8000	4
17			WebAttack-XSS	0.4508	0.4231	0.4365	130
18							
19			accuracy			0.9990	566149
20			macro avg	0.9087	0.9322	0.9173	566149
21			weighted avg	0.9990	0.9990	0.9990	566149
22							



VALIDATION-MACRO AVG: PRECISION 0.8586 / RECALL 0.8148 / F1 0.8284

TEST-MACRO AVG: PRECISION 0.9087 / RECALL 0.9322 / F1 0.9173

## 5. 평가

딥러닝MLP TEST-MACRO AVG: PRECISION 0.56 / RECALL 0.62 / F1 0.56

머신러닝XGBOOST TEST-MACRO AVG: PRECISION 0.90 / RECALL 0.93 / F1 0.91

정형 데이터와 불균형 라벨 분포에서는 복잡한 딥러닝 구조보다 전통적인 머신러닝 알고리즘이 더 효율적일 수 있다.

## 6. 향후계획

-양상블 확장

파일별(PER-FILE) MLP 모델과 글로벌 모델을 조합하는 양상블을 적용하여 단일 모델 대비 안정적이고 균형 잡힌 탐지 성능 확보

-시각화

FLASK 등을 활용하여 웹에서 동작할수 있는 구조로 확장

## 7. 출처

CIC-IDS-2017데이터-KAGGLE(CHETHANH N)

[HTTPS://WWW.KAGGLE.COM/DATASETS/CHETHUHN/NETWORK-INTRUSION-DATASET/DATA](https://www.kaggle.com/datasets/chethuhn/network-intrusion-dataset/data)

## 7. 출처

-END-